

DATASET

TS. Hoàng Quốc Việt



Nội dung



Giới thiệu



Thư viện Pandas



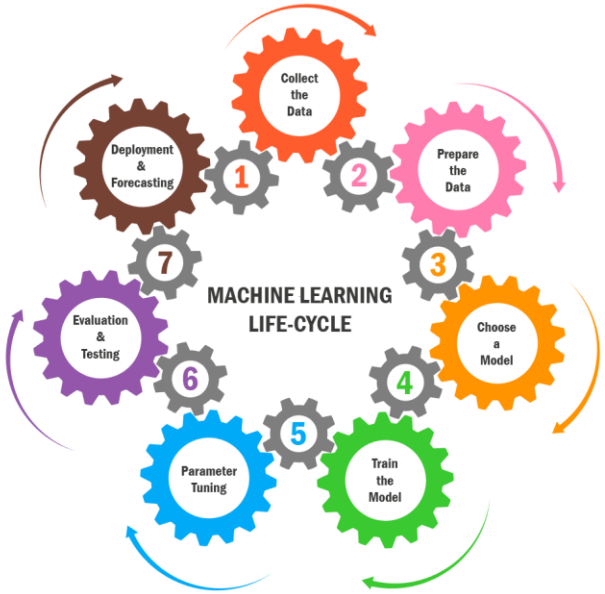
DataFrame



Làm việc với file CSV

I. Giới thiệu

- Dataset: Bộ dữ liệu dùng để huấn luyện các mô hình học máy.
- Data: Image, text, numeric…
- Kaggle cung cấp nhiều bộ dataset, code…

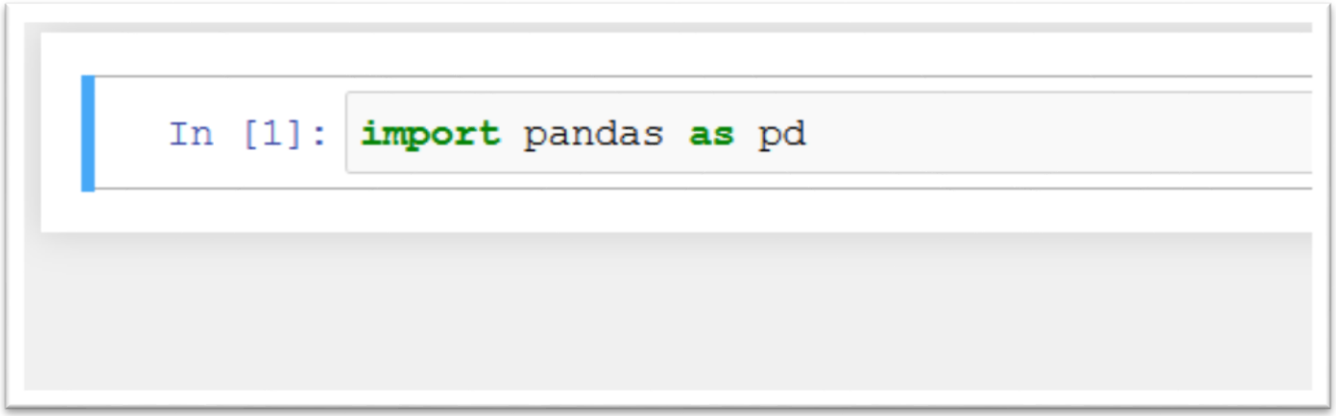


II. Thư viện Pandas

- Pandas là một thư viện chứa các công cụ lưu trữ với dữ liệu có cấu trúc bậc cao.
- Pandas được thiết kế nhằm mục đích đơn giản và làm cho việc phân tích dữ liệu trở nên nhanh chóng và dễ dàng.
- Pandas được xây dựng trên nền của NumPy làm cho nó dễ dàng được sử dụng trong các ứng dụng xoay quanh NumPy.

II. Thư viện Pandas

- Cài đặt:
  - conda install pandas #khi làm việc với Anaconda
  - pip install pandas # Cài đặt bằng pip
- Sử dụng:
  - import pandas as pd



III. DataFrame

- Series là mảng một chiều có thể chứa mọi kiểu dữ liệu (integer, string, floating point numbers, Python objects, etc).

Index	Data
1	'A'
2	'B'
3	'C'
4	'D'
5	'E'

III. DataFrame

- Tạo Series: Hàm *pandas.Series* được dùng để tạo một đối tượng Series có cấu trúc như sau:

s = pd.Series(data, index=index)

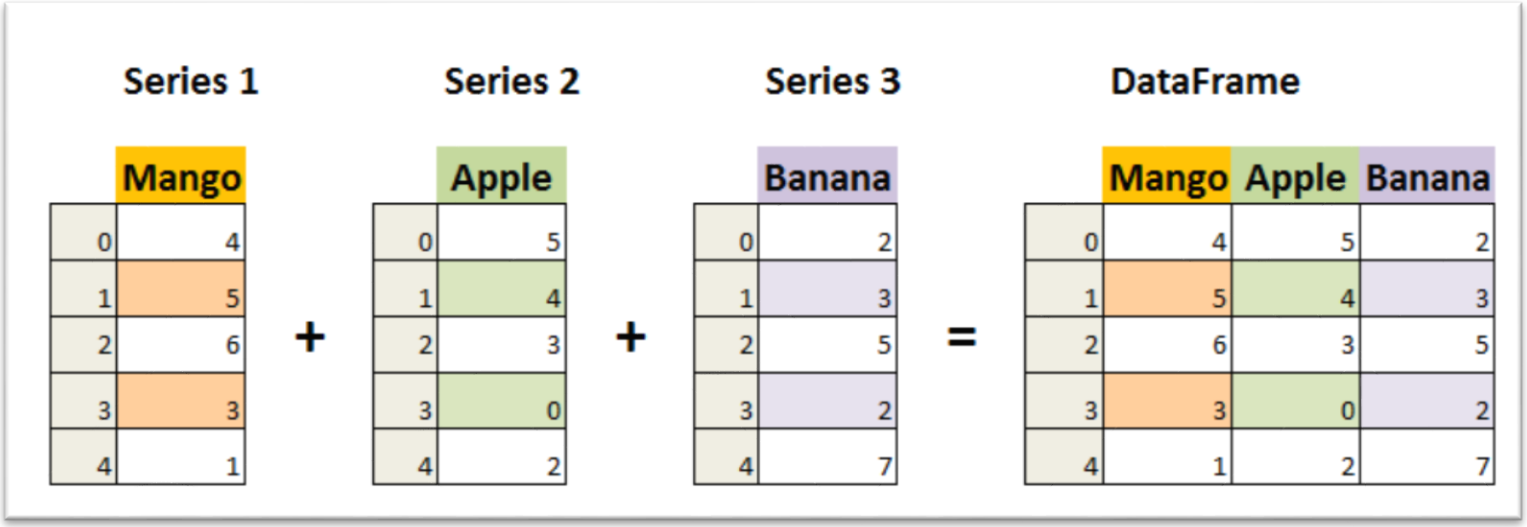
  - *data*: là các đối tượng chứa dữ liệu (list, ndarray, số nguyên,…)
  - *index*: là một list chứa các nhãn (label).

```
In [2]: #tạo một Series chứa chiều cao (cm)của 5 bạn trong lớp
        height=pd.Series([163,165,168,164,175],index=["Hùng","Nam","Long","Đặng","Tùng"])
        height

Out[2]: Hùng    163
        Nam     165
        Long    168
        Đặng    164
        Tùng    175
        dtype: int64
```

III. DataFrame

- DataFrame là cấu trúc dữ liệu dán nhãn 2 chiều với các cột có thể có kiểu dữ liệu khác nhau.
- DataFrame là được ghép lại từ nhiều Series với nhau.
- Mỗi cột của DataFrame sẽ có kiểu dữ liệu dtypes tương ứng với Series tạo nên nó.



III. DataFrame

- Tạo DataFrame từ Series: Người dùng cũng có thể chỉ định các index cho DataFrame muốn tạo, những index không được liệt kê sẽ không xuất hiện trong DataFrame:

```
In [10]: dict={
             "Mango":pd.Series([4,5,6,3,1], index=[0,1,2,3,4]),
             "Apple":pd.Series([5,4,3,0,2],index=[0,1,2,3,4]),
             "Banana":pd.Series([2,3,5,2,7], index=[0,1,2,3,5])
         }
         df=pd.DataFrame(dict, index=[2,3,5])
         df
```

Out[10]:

	Mango	Apple	Banana
2	6.0	3.0	5
3	3.0	0.0	2
5	NaN	NaN	7

```
df = pd.DataFrame({'name': ['Raphael', 'Donatello'],
                   'mask': ['red', 'purple'],
                   'School': ['Chicago', 'Vin']})
df
```

III. DataFrame

- Người dùng cũng có thể chỉ định những cột nào được xuất hiện trong DataFrame:

```
In [13]: dict={
             "Mango":pd.Series([4,5,6,3,1], index=[0,1,2,3,4]),
             "Apple":pd.Series([5,4,3,0,2],index=[0,1,2,3,4]),
             "Banana":pd.Series([2,3,5,2,7], index=[0,1,2,3,5])
         }
         df=pd.DataFrame(dict, index=[2,3,5], columns=["Mango","Apple"])
         df
```

Out[13]:

	Mango	Apple
2	6.0	3.0
3	3.0	0.0
5	NaN	NaN

IV. Làm việc với file CSV

- DataFrame cũng có thể được tạo ra từ các tệp dữ liệu có cấu trúc dạng bảng như file CSV.

[2]:
```
# Read file CSV
import pandas as pd

# Đọc toàn bộ file CSV
path = 'Dataset/COVID19_state.csv'
# path = 'COVID19_state.csv' # File CSV cùng cấp với file Jupyter notebook
df = pd.read_csv(path)

# Đọc một số cột
column_name = ['State', 'Tested', 'Infected', 'Deaths']
df2 = pd.read_csv(path,usecols=column_name)

# Hiển thị thông tin DataFrane
df
```

[2]:

	State	Tested	Infected	Deaths	Population	Pop Density	Gini	ICU Beds	Income	GDP	...	Hospitals	Health Spending	Pollution	Med-Large Airports	Temperature	Urban
0	Alaska	8348	285	9	734002	1.2863	0.4081	119	59687	73205	...	21	11064	6.4	1.0	26.60	66.0
1	Alabama	33050	3953	114	4908621	96.9221	0.4847	1533	42334	45219	...	101	7281	8.1	1.0	62.80	59.0
2	Arkansas	21203	1498	32	3038999	58.4030	0.4719	732	42566	42454	...	88	7408	7.1	0.0	60.40	56.2
3	Arizona	44096	3806	131	7378494	64.9550	0.4713	1559	43650	48055	...	83	6452	9.7	1.0	60.30	89.8
4	California	215400	23338	758	39937489	256.3727	0.4899	7338	62586	74205	...	359	7549	12.8	9.0	59.40	95.0
5	Colorado	39580	7941	329	5845526	56.4011	0.4586	1597	56846	63882	...	89	6804	6.7	1.0	45.10	86.2
6	Connecticut	45841	13989	671	3563077	735.8689	0.4945	674	74561	76342	...	32	9859	7.2	1.0	49.00	88.0

IV. Làm việc với file CSV

- Truy xuất trong DataFrame.

Cách thức	Kí hiệu	Kết quả trả về
Chọn ô	df.at[row/columns]	Value
Chọn ô bằng index	df.iat[irow/icolumns]	Value
Chọn cột	df[col]	Series
Chọn hàng bằng nhãn (location)	df.loc[label]	Series
Chọn hàng bằng vị trí số (integer location)	df.iloc[loc]	Series
Cắt (slice) các hàng	df[5:10]	DataFrame
Chọn các hàng bằng Boolean vector	df[bool_vec]	DataFrame

IV. Làm việc với file CSV

- Hiển thị thông tin DataFrame (File CSV).

```
[5]: # Hiển thị dữ liệu
df.head(5) # 5 hàng đầu tiên
# df.sample(5) # 5 hàng ngẫu nhiên
```

[5]:

	State	Tested	Infected	Deaths	Population	Pop Density	Gini	ICU Beds	Income	GDP	...	Hospitals	Health Spending	Pollution	Med-Large Airports	Temperature	Urban	Age 0-25	Age 26 5
0	Alaska	8348	285	9	734002	1.2863	0.4081	119	59687	73205	...	21	11064	6.4	1.0	26.6	66.0	0.36	0.3
1	Alabama	33050	3953	114	4908621	96.9221	0.4847	1533	42334	45219	...	101	7281	8.1	1.0	62.8	59.0	0.33	0.3
2	Arkansas	21203	1498	32	3038999	58.4030	0.4719	732	42566	42454	...	88	7408	7.1	0.0	60.4	56.2	0.34	0.3
3	Arizona	44096	3806	131	7378494	64.9550	0.4713	1559	43650	48055	...	83	6452	9.7	1.0	60.3	89.8	0.33	0.3
4	California	215400	23338	758	39937489	256.3727	0.4899	7338	62586	74205	...	359	7549	12.8	9.0	59.4	95.0	0.33	0.4

5 rows × 26 columns

IV. Làm việc với file CSV

- Tách một DataFrame con từ một DataFrame:

```
df_sub = df[['State', 'Tested']]
df_sub.head(5)
# df_sub.describe()
```

	State	Tested
0	Alaska	8348
1	Alabama	33050
2	Arkansas	21203
3	Arizona	44096
4	California	215400

IV. Làm việc với file CSV

- Truy xuất và hiển thị dữ liệu:

```
# Hiển thị dữ liệu
df.head(5)
df.sample(5)

df.at[1,"State"] # Lựa chọn 1 cell
df.iat[1,1] # Lựa chọn 1 cell

df["State"].head() # Chọn 1 cột
df.loc[2] # Chọn hàng 2
df.iloc[2] # Chọn hàng 2 (cho kết quả tương tự)
```

- Slice DataFrame:

```
# Slice DataFrame
# df[2:] # Lấy từ 2 đến hết
# df[:4] # Lấy từ đầu đến hết hàng 3
df[2:4] # Lấy hàng 23
```

	State	Tested	Infected	Deaths	Population	Pop Density	Gini	ICU Beds	Income	GDP	...	Hospitals	Health Spending	Pollution	Med-Large Airports	Temperature	Urban	Age 0-25	Age 26-54
2	Arkansas	21203	1498	32	3038999	58.403	0.4719	732	42566	42454	...	88	7408	7.1	0.0	60.4	56.2	0.34	0.37
3	Arizona	44096	3806	131	7378494	64.955	0.4713	1559	43650	48055	...	83	6452	9.7	1.0	60.3	89.8	0.33	0.36

2 rows × 26 columns

IV. Làm việc với file CSV

- Truy vấn trên DataFrame:

```
#  Hiển thị dữ liệu phức tạp hơn (xử lý dữ liệu)
import pandas as pd
path = 'COVID19_state.csv'
df = pd.read_csv(path)

#
df['Deaths']
df.describe()

# Lấy ngẫu nhiên 10 bang có số ca tử vong >100
df[df['Deaths'] > 100] # Lấy tất cả
df[df['Deaths'] > 100].sample(10)

#  Lấy tổng số ca tử vong, lớn nhất, nhỏ nhâ
df['Deaths'].sum()
df['Deaths'].max()

# Hiển thị thông tin của bang có số ca tử vong lớn nhất
df[df.Deaths==df['Deaths'].max()]

# Hiển thị tên bang có số ca tử vong lớn nhất
df["State"][df.Deaths==df['Deaths'].max()]
```

IV. Làm việc với file CSV

- Truy vấn trên DataFrame:

```
# Sắp xếp theo GDP: ascending=True: Sắp xếp từ tấp đến cao
df.sort_values(by=['GDP'], ascending=True).head(5)
# df.sort_values(by=['GDP']).head(5)

# Đếm xem có bao nhiêu bang
len(df['State'].unique())
```

- Lưu dữ liệu ra file CSV:

```
df_sub.to_csv('out.csv')
```

Tài liệu tham khảo

- [1]. https://pandas.pydata.org/
- [2]. https://medium.com/
- [3]. https://towardsdatascience.com/
- [4]. https://machinelearningcoban.com/

Thank You !

Question?